Proyecto de aula de Inteligencia Artificial

Predicción de reingresos hospitalarios a 30 días

Fase 1 Formulación y exploración

Prototipo con datos de hospitalizaciones de pacientes con diabetes

Equipo Grupo 04

Michel Custodes
Ivan Güette
Maira Torres

Ingeniería de Sistemas
Séptimo semestre
Valledupar Cesar
2026

Índice

1 Título....2
2 Planteamiento del problema....2
3 Justificación....2
4 Objetivos....3
5 Estado del arte....4
6 Tipo de problema de IA....4
7 Fuentes de datos y metodología de datos....5
8 Análisis exploratorio de datos....6
9 Cronograma de trabajo....8
10 Referencias....8

1 Título

Predicción de reingresos hospitalarios a 30 días mediante aprendizaje automático en pacientes con diabetes.

2 Planteamiento del problema

Un reingreso hospitalario poco después del alta representa un nuevo episodio de atención que merece ser estudiado. Para este proyecto interesa reconocer, a partir de la información disponible al finalizar una hospitalización, qué registros presentan mayor probabilidad de un reingreso temprano. El resultado esperado es una estimación de riesgo que pueda revisarse en un prototipo académico de apoyo al seguimiento posterior al egreso.

La dificultad consiste en que el desenlace depende de una combinación de características y no de una sola variable. La duración de la estancia, el uso previo de servicios, los diagnósticos y el tratamiento registrado pueden contener información útil, pero también reflejan la complejidad de cada caso y la forma en que se documentó su atención. Además, los reingresos tempranos son minoritarios. Un sistema que clasifique casi todos los casos como negativos podría parecer preciso y, aun así, omitir la mayoría de los eventos que se busca identificar.

Trabajaremos con Diabetes 130-US Hospitals for Years 1999-2008, disponible en UCI (Clore et al., 2014). La unidad de análisis será la hospitalización; una misma persona puede tener varios registros. El universo del proyecto queda delimitado a encuentros hospitalarios en los que se registró diabetes, por lo que los resultados no se presentarán como aplicables a cualquier enfermedad, hospital o población.

La pregunta que orienta el proyecto es la siguiente: ¿en qué medida un modelo de Gradient Boosting mejora la identificación de reingresos tempranos frente a una regresión logística y un clasificador de referencia, utilizando las características registradas durante la hospitalización y una evaluación que mantenga separados a los pacientes?

La variable original distingue <30, >30 y NO. Se considerará positivo el reingreso registrado en menos de 30 días y negativo las otras dos categorías. Se conserva la denominación del tema «a 30 días», pero el análisis respeta el significado literal de <30. El archivo no permite identificar el día exacto del retorno, distinguir con certeza reingresos programados o evitables, ni establecer que NO equivale a ausencia absoluta de reingreso fuera de la fuente.

3 Justificación

El interés del proyecto es comprobar si los datos disponibles permiten ordenar los casos por probabilidad de reingreso y comunicar esa información de manera comprensible. Una eventual utilidad asistencial requeriría validación adicional y una estrategia de seguimiento definida por profesionales de salud. En esta etapa, la contribución será metodológica: construir un proceso verificable de exploración, preparación y evaluación, sin atribuir al modelo la capacidad de decidir tratamientos o altas.

Desde la formación en Ingeniería de Sistemas, el problema reúne tareas que suelen aparecer en proyectos reales de analítica: variables numéricas y categóricas, datos incompletos, observaciones repetidas y una clase de interés poco frecuente. También obliga a diferenciar un buen resultado estadístico de una solución utilizable. Frizzell et al. (2017) encontraron un desempeño modesto y similar entre métodos tradicionales y de aprendizaje automático, lo que justifica comparar alternativas sin dar por hecho que el algoritmo más complejo será superior.

La base pública permite comenzar sin depender de convenios con una institución hospitalaria. La implementación con Python y scikit-learn, junto con un tablero posterior en Power BI, resulta abordable durante el semestre. Su adaptación a Colombia quedará planteada como trabajo futuro: necesitaría datos locales autorizados, una definición equivalente del desenlace y una evaluación externa. No se afirmará que esta primera fase utiliza RIPS ni información de hospitales del Cesar.

4 Objetivos

Objetivo general

Desarrollar un prototipo de inteligencia artificial que estime la probabilidad de reingreso hospitalario temprano en pacientes con diabetes, mediante modelos de aprendizaje automático y la presentación de sus resultados en un tablero de Power BI, como ejercicio académico de apoyo al análisis del seguimiento posterior al egreso.

Objetivos específicos

1. Caracterizar y preparar el conjunto público de hospitalizaciones mediante un análisis exploratorio reproducible que identifique la distribución del reingreso, los valores faltantes, los registros repetidos y las relaciones entre las variables disponibles.
2. Entrenar y comparar un modelo de Gradient Boosting con una regresión logística y un clasificador de referencia, utilizando una partición por paciente y métricas adecuadas para evaluar discriminación, detección de reingresos y calibración de las probabilidades.
3. Integrar los resultados del modelo seleccionado en un tablero de Power BI que permita consultar las estimaciones de riesgo y los indicadores de evaluación, documentando las limitaciones, los posibles sesgos y las condiciones de uso del prototipo.

Metas de evaluación

Las metas siguientes son criterios propuestos para las fases 2 y 3; no corresponden a resultados ya obtenidos. Si los datos no permiten alcanzarlas, se documentarán las causas y el desempeño observado. No se alterará el conjunto de prueba para mejorar artificialmente los indicadores.

Aspecto	Criterio propuesto
Comparación mínima	Clasificador mayoritario, regresión logística y Gradient Boosting sobre las mismas particiones. MLP sencilla como extensión opcional.
Métrica principal	Average precision (AP) superior a la referencia de prevalencia y comparación explícita con la regresión logística. Meta exploratoria: AP ≥ 1,5 veces la prevalencia.
Discriminación	Meta exploratoria de ROC-AUC ≥ 0,65. Reportar incertidumbre y diferencias entre modelos, incluso si no se alcanza.
Detección de positivos	Explorar un umbral con sensibilidad ≥ 0,60 y precisión ≥ 0,20 en validación. Informar la proporción de registros que produciría alertas.
Calibración y errores	Curva de calibración, puntuación Brier, F1 y matriz de confusión. Examinar falsos negativos y falsos positivos.
Rigor y reproducibilidad	Cero pacientes compartidos entre conjuntos; transformaciones ajustadas en entrenamiento; semilla, versiones y decisiones registradas en el notebook.

La AP resume la relación entre precisión y sensibilidad al variar el umbral; se calculará con average_precision_score y se distinguirá del área obtenida por integración trapezoidal. Sensibilidad indica cuántos reingresos se identifican; precisión, cuántas alertas corresponden a un reingreso. Ambas deben leerse juntas. El umbral dependerá de ese equilibrio y no se fijará automáticamente en 0,50 (Scikit-learn developers, s. f.).

El tablero de la fase final mostrará cantidad de hospitalizaciones y pacientes, frecuencias observadas, distribución de probabilidades y métricas del modelo. Se diferenciarán los datos observados de las predicciones; una probabilidad estimada no se presentará como diagnóstico ni como certeza individual.

5 Estado del arte

Los antecedentes seleccionados permiten contrastar tres aspectos del problema: la construcción de una cohorte con diabetes, el rendimiento de los modelos tabulares y el uso de historias clínicas más completas. Sus resultados no son directamente comparables entre sí porque cambian las poblaciones, las variables y la definición del reingreso.

Strack et al. (2014) estudiaron 69.984 encuentros después de depurar la base de origen, conservar una hospitalización por paciente y excluir fallecimientos y egresos a hospice. Utilizaron regresión logística para analizar la relación entre medición de HbA1c y reingreso temprano, considerando otras características clínicas. Este antecedente resulta especialmente cercano por ser el estudio asociado al dataset. Aporta criterios para interpretar las variables y construir la cohorte, aunque su propósito de asociación no equivale a validar nuestro clasificador. Adoptaremos sus exclusiones de fallecimiento y hospice; conservaremos las hospitalizaciones repetidas con partición agrupada por paciente.

Frizzell et al. (2017) compararon regresión logística y otros métodos con redes bayesianas, Random Forest y Gradient Boosting en 56.477 pacientes hospitalizados por insuficiencia cardiaca. La discriminación fue similar y limitada: el estadístico C fue aproximadamente 0,61 para Gradient Boosting y 0,62 para regresión logística. El estudio respalda incluir un modelo sencillo como comparación y evitar que la elección de IA se base únicamente en su complejidad. Su población y fuentes de datos difieren de las del presente proyecto, de modo que esos valores sirven como antecedente metodológico, no como resultados transferibles.

Rajkomar et al. (2018) desarrollaron modelos de aprendizaje profundo sobre historias clínicas de dos centros académicos y analizaron 216.221 hospitalizaciones. Para reingresos no planeados a 30 días, el apartado de resultados informa AUROC al egreso de 0,77 y 0,76 en los dos centros. El trabajo muestra el potencial de información clínica longitudinal más amplia. También evidencia una diferencia importante con nuestra propuesta: el archivo de UCI es una tabla resumida y no permite reproducir esa representación ni asumir que una MLP sencilla obtendrá el mismo desempeño.

La propuesta no pretende introducir un algoritmo nuevo. Su aporte será comparar modelos con una definición explícita del desenlace, controlar la repetición de pacientes y comunicar sus resultados con claridad. La principal brecha para una aplicación local es la disponibilidad de información colombiana comparable y su validación; esa brecha no se resuelve sustituyendo nombres de variables ni presentando la base estadounidense como si correspondiera al contexto regional.

6 Tipo de problema de IA

Se trata de aprendizaje supervisado para clasificación binaria sobre datos tabulares. La entrada será un conjunto de características de la hospitalización y de utilización previa de servicios; la salida, una probabilidad estimada del evento <30. Aunque el modelo produce un valor entre 0 y 1, el desenlace sigue siendo categórico: el proyecto no consiste en predecir el número de días hasta un nuevo ingreso.

La regresión logística ofrecerá una comparación interpretable. Gradient Boosting combinará árboles para capturar relaciones no lineales e interacciones. Si el desarrollo lo permite, se evaluará una red neuronal multicapa sencilla, con escalado y regularización. La implementación principal utilizará pandas, NumPy, matplotlib y scikit-learn; TensorFlow/Keras quedará como alternativa para la MLP, sin ser una dependencia obligatoria de esta fase.

El punto de predicción se sitúa al finalizar la hospitalización. Así se justifica usar duración de estancia, medicamentos y procedimientos acumulados. Una futura aplicación deberá confirmar cuándo quedan disponibles los diagnósticos codificados; si se registran después del egreso, se excluirán del modelo operativo. No se incorporará información generada por el reingreso que se intenta predecir.

7 Fuentes de datos y metodología de datos

Fuente seleccionada y alcance

La fuente principal es el dataset de Clore et al. (2014), con licencia CC BY 4.0. Se descargaron diabetic_data.csv e IDS_mapping.csv desde UCI. El primer archivo contiene 101.766 filas y 50 columnas; el segundo describe códigos de ingreso y egreso. De las 50 columnas, 2 son identificadores y 1 corresponde al desenlace: las 47 restantes son características originales, antes de su selección y transformación.

Los RIPS se consideran una posible fuente para una ampliación posterior, condicionada al acceso autorizado y a la disponibilidad de identificadores vinculables, fechas de ingreso y egreso, diagnósticos y seguimiento suficiente. No forman parte de la base utilizada ni se requiere obtenerlos para completar este prototipo.

Carga y organización de variables

Grupo	Variables y tratamiento inicial
Identificación	encounter_id identifica el encuentro; patient_nbr agrupa personas. Se conservan para trazabilidad y partición, no como predictores.
Datos demográficos	age por intervalos y gender como categoría. race se reserva para revisión de diferencias entre subgrupos y se excluye del modelo principal.
Hospitalización	time_in_hospital, num_lab_procedures, num_procedures, num_medications y number_diagnoses como conteos o duración.
Uso previo de servicios	number_outpatient, number_emergency y number_inpatient: atenciones registradas durante el año anterior.
Clínica y administración	diag_1 a diag_3, tratamientos, resultados de laboratorio y códigos de ingreso y egreso. Los códigos administrativos son categorías.
Resultado	readmitted se conserva para auditoría y se recodifica como y: 1 para <30; 0 para >30 o NO.

Preparación y control de calidad

La lectura convierte ? en ausencia y preserva None en A1Cresult y max_glu_serum, donde significa prueba no realizada. Se retirarán inicialmente weight por su escasa cobertura, payer_code por su incompletitud y dependencia del sistema de aseguramiento, y las columnas constantes examide y citoglipton. medical_specialty conservará una categoría de ausencia. Los diagnósticos se tratarán como códigos, sin convertir a valores numéricos las categorías V y E.

Se excluyeron 2.423 egresos por fallecimiento o a hospice, correspondientes a los códigos 11, 13, 14, 19, 20 y 21. La cohorte resultante contiene 99.343 hospitalizaciones, 69.990 pacientes y 11.314 positivos, equivalentes al 11,39 %. Se mantienen los demás egresos; en la fase 2 se evaluará el efecto de excluir transferencias entre instituciones. Las visitas repetidas de una persona no se consideran duplicados erróneos.

Partición y evaluación posterior

Se aplicó StratifiedGroupKFold para obtener 59.605 registros de entrenamiento, 19.868 de validación y 19.870 de prueba, aproximadamente 60/20/20. Ningún paciente pertenece a más de un conjunto. Las asociaciones del EDA se examinaron únicamente en entrenamiento. La imputación, codificación y eventual escalado se ajustarán dentro de pipelines; la búsqueda de hiperparámetros usará cinco pliegues agrupados en entrenamiento (Scikit-learn developers, s. f.).

El umbral se elegirá en validación y la prueba se evaluará una sola vez con el flujo congelado. Las probabilidades se revisarán mediante calibración y Brier; los intervalos de confianza se estimarán remuestreando pacientes completos. El archivo no contiene fechas exactas ni un identificador de hospital, por lo que esta partición no sustituye una validación temporal o externa.

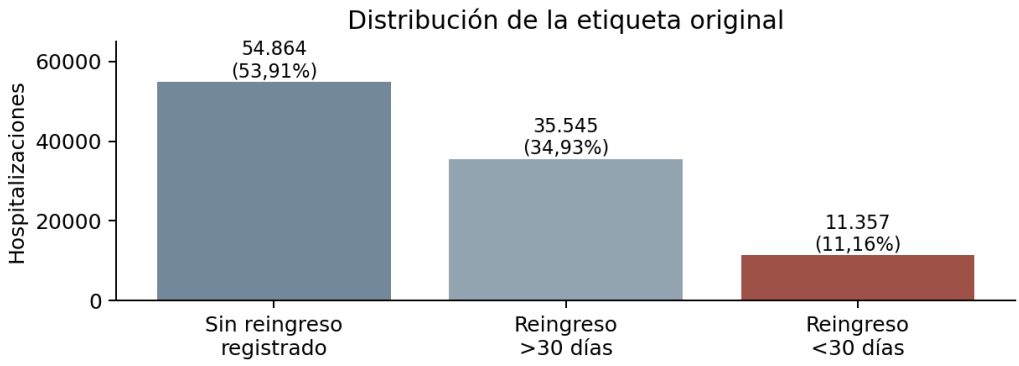
8 Análisis exploratorio de datos

Estructura y distribución del desenlace

El notebook Fase1_EDA_Reingresos_Grupo04.ipynb contiene la carga, el diccionario de variables, las estadísticas, las gráficas y los controles de calidad, con celdas ejecutadas y salidas visibles. Las frecuencias generales describen la base original; las asociaciones con el reingreso se exploran únicamente en entrenamiento.

La base incluye 71.518 pacientes distintos. No se encontraron filas exactamente duplicadas ni encounter_id repetidos. Sin embargo, 16.773 pacientes tienen varias hospitalizaciones, con un máximo de 40 por persona. Esta estructura explica la necesidad de separar los datos por patient_nbr en lugar de repartir aleatoriamente las filas.

Figura 1. Distribución del desenlace en las 101.766 hospitalizaciones originales.



Los 11.357 registros positivos representan el 11,16 %; los negativos suman 90.409, equivalentes al 88,84 %. La razón es de aproximadamente ocho negativos por positivo. Un clasificador que siempre anuncie ausencia de reingreso temprano alcanzaría 88,84 % de exactitud y sensibilidad cero. Por ello, la exactitud global no será el criterio principal de selección.

Valores faltantes y categorías especiales

Tabla 1. Valores ausentes identificados como ? en el archivo original.

Variable	Registros	Porcentaje
weight	98.569	96,86 %
medical_specialty	49.949	49,08 %
payer_code	40.256	39,56 %
race	2.273	2,23 %
diag_3	1.423	1,40 %
diag_2	358	0,35 %
diag_1	21	0,02 %

El peso está ausente en el 96,86 % de los registros, por lo que imputarlo para casi toda la base aportaría supuestos difíciles de sostener. La especialidad médica y el pagador presentan ausencias importantes, pero exigen decisiones distintas según su utilidad. También aparecen tres registros con gender igual a Unknown/Invalid y códigos administrativos que significan NULL, Not Available o Not Mapped; estos últimos no son nulos de lectura y se identificaron con IDS_mapping.csv.

None en los exámenes y No en los tratamientos son categorías con significado, no datos perdidos. examide y citoglipton son constantes y se retirarán. El notebook distingue las ausencias reales, los códigos sin información y las variables constantes.

Estadísticas descriptivas y observaciones extremas

Tabla 2. Estadísticas seleccionadas de la base original. DE: desviación estándar.

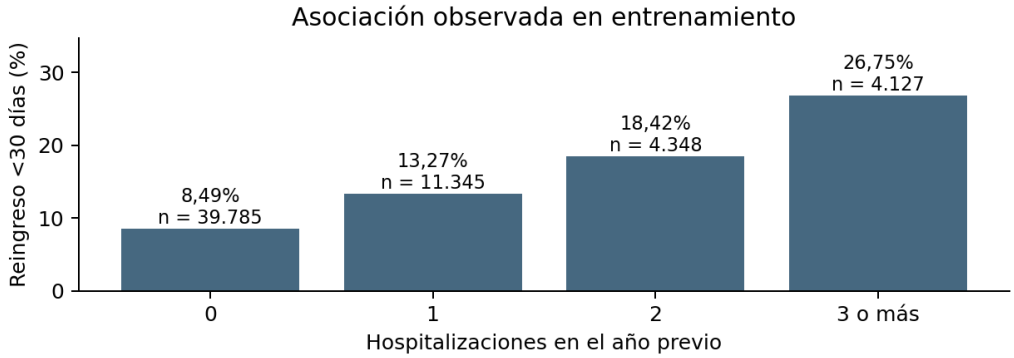
Variable	Media	DE	Mediana	Q1 a Q3	Rango
Estancia en días	4,40	2,99	4	2 a 6	1 a 14
Pruebas de laboratorio	43,10	19,67	44	31 a 57	1 a 132
Medicamentos	16,02	8,13	15	10 a 20	1 a 81
Ingresos en el año previo	0,64	1,26	0	0 a 1	0 a 21
Diagnósticos	7,42	1,93	8	6 a 9	1 a 16

La estancia media fue de 4,40 días y la mediana de 4 días. La mitad central de los registros se situó entre 2 y 6 días. Se observaron hasta 81 medicamentos y 21 ingresos previos, valores que requieren revisión, pero no se consideran errores por ser altos. No hubo estancias fuera de 1 a 14 días ni conteos negativos en las variables examinadas.

En entrenamiento, la regla de 1,5 veces el rango intercuartílico señaló 1.459 observaciones con más de 35 medicamentos (2,45 %) y 1.218 con estancias superiores a 12 días (2,04 %). Se conservaron para el análisis. En consultas y urgencias previas, el rango intercuartílico es cero por la concentración de conteos iguales a cero; aplicar una eliminación automática descartaría registros válidos.

Relaciones exploratorias con el reingreso

Figura 2. Frecuencia de reingreso según hospitalizaciones previas, solo en entrenamiento.



La frecuencia observada fue de 8,49 % entre registros sin hospitalizaciones previas, 13,27 % con una, 18,42 % con dos y 26,75 % con tres o más. Esta diferencia justifica conservar el uso previo de servicios como característica candidata. Es una asociación descriptiva: puede reflejar condiciones de salud, acceso o continuidad de atención y no demuestra causalidad. Los tamaños de cada grupo se incluyen en la figura para evitar comparar porcentajes sin contexto.

El notebook añade cruces por edad, género, categoría racial, HbA1c y tratamiento; distribuciones de estancia y medicamentos; y una matriz de correlaciones de Spearman. Estas exploraciones no establecen por sí solas relevancia clínica ni prueban que una variable mejorará el modelo. El conjunto de prueba se reserva para la evaluación final.

Limitaciones e implicaciones para el modelado

El dataset corresponde a 1999–2008 y refleja criterios de selección y registro de su fuente. No permite observar todos los reingresos fuera de la red ni determinar evitabilidad. La ausencia de variables sociales y de seguimiento puede limitar la predicción. Se reportarán diferencias entre subgrupos sin atribuirlas a causas biológicas; excluir race del modelo principal no elimina el sesgo que pueda transmitirse por otras variables. Estas restricciones delimitan el alcance académico de los resultados.

9 Cronograma de trabajo

Se propone una programación relativa de 12 semanas, conforme a las tres fases de la guía. Las fechas calendario y las semanas de parciales se acordarán con el docente. La coordinación indicada es una distribución propuesta; los tres integrantes revisarán el código, los resultados y los documentos.

Tabla 3. Diagrama de Gantt por semanas. X indica trabajo previsto; E indica entrega.

Actividad	Coord.	1	2	3	4	5	6	7	8	9	10	11	12
Propuesta y EDA	Michel	X	E										
Limpieza y partición	Michel			X	X								
Modelos y ajuste	Iván				X	X	X						
Evaluación e informe F2	Grupo						X	E					
Optimización y calibración	Iván								X	X			
Power BI y prototipo local	Maira								X	X	X		
Informe final y video	Grupo										X	X	X
Ensayo y sustentación	Grupo											X	E

Actividad	Coord.	1	2	3	4	5	6	7	8	9	10	11	12
Repositorio y revisión	Grupo	X	X	X	X	X	X	X	X	X	X	X	X

Hitos: semana 2, propuesta, notebook y exposición de 10–15 minutos; semana 7, modelos comparados, informe de 8–12 páginas y repositorio; semana 12, prototipo local documentado, tablero, informe de 12–20 páginas, video de 3–5 minutos y sustentación. El repositorio registrará avances durante todo el semestre.

La viabilidad depende de controlar el alcance. Si la MLP retrasa las entregas, se priorizará la comparación entre regresión logística y Gradient Boosting. Power BI consumirá tablas exportadas por Python. La integración se iniciará después de definir el modelo y sus campos de salida; no se requiere contratar infraestructura ni acceder a datos privados para esta prueba de concepto.

10 Referencias

Clore, J., Cios, K., DeShazo, J. y Strack, B. (2014). Diabetes 130-US Hospitals for Years 1999-2008 [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5230J

Strack, B., DeShazo, J. P., Gennings, C., Olmo, J. L., Ventura, S., Cios, K. J. y Clore, J. N. (2014). Impact of HbA1c measurement on hospital readmission rates: Analysis of 70,000 clinical database patient records. BioMed Research International, 2014, 781670. https://doi.org/10.1155/2014/781670

Frizzell, J. D., Liang, L., Schulte, P. J., Yancy, C. W., Heidenreich, P. A., Hernandez, A. F., Bhatt, D. L., Fonarow, G. C. y Laskey, W. K. (2017). Prediction of 30-day all-cause readmissions in patients hospitalized for heart failure: Comparison of machine learning and other statistical approaches. JAMA Cardiology, 2(2), 204–209. https://doi.org/10.1001/jamacardio.2016.3956

Rajkomar, A. et al. (2018). Scalable and accurate deep learning with electronic health records. npj Digital Medicine, 1, 18. https://doi.org/10.1038/s41746-018-0029-1

Scikit-learn developers. (s. f.). Cross-validation: Evaluating estimator performance. Documentación oficial. Consultar documentación

Scikit-learn developers. (s. f.). average_precision_score. Documentación oficial. Consultar documentación